

01 PROBLEM — TEK CÜMLEDE

Model tek başına durur. Sorarsın, cevap verir, biter. **Ajan = model + döngü** — ve döngüyü kesme sorusu modelde hiç yoktu.

En doğal cevap "model kendi karar versin". Pratikte en kötü cevap: model her turda yalnızca **bir sonraki adıma** bakıyor. Kaç kez aynı şeyi denediğini, ne harcadığını görmüyor.

"Her döngüye modelin yargısına bağlı olmayan sert bir durdurma gerekiyor, çünkü model, işin bitip bitmediği konusunda **yanılması en muhtemel bileşendir.**"

— Arize

Anthropic referans computer-use döngüsü K

```
while True:
    response = model(messages)
    if not tool_use:
        return messages # tek cikis
    result = run_tools(...)
    messages.append(result)
```

Tur sayacı yok · döngü tespiti yok · bütçe yok.

Kesme yetkisi tamamen modelde — "yanılması en muhtemel bileşen"de.

02 KANIT — ÜÇ ÖLÇÜM

MAST T

1642 açıklamalı yürütme izi, 7 framework, 14 hata modu.

Adım tekrarı (en sık)	%15,7
Durma koşulunu tanınamama	%12,4
Toplam	%28,1

Bütün hataların dörtte birinden fazlası tek başlıkta: **ne zaman duracağını bilmiyor.**

Token Budgets T

21 framework, 2023–2026, **63 doğrulanmış üretim olayı**. Her biri GitHub issue + maintainer beyanı + dolar zararı ile. Cohen's $\kappa = 0,837$.

"Katalogda, bir kullanıcı **parasını ödemedi** önce engellenmiş tek bir bütçe aşımı vakası bulamadık."

Düzeltilmeler aynı gün geliyor — **ama fatura geldikten sonra.**

Somut olaylar T

MAST-014 — tek bir gözlemci LLM çağrısında **2 milyon token**. Gözlemlenebilirlik katmanının kendisi maliyet amplifikatörü olmuş.

MAST-004 — **TokenLimiter** döngü iterasyonu başına tetiklenmiyor. **Sınır var, yanlış yerde.**

03 SEKTÖR NE YAPIYOR — 31 HARNESS, KAYNAK KODUNDAN K

Varsayılan sınırlar

HARNESS	VARSAYILAN
smolagents	max_steps = 20
LangGraph	recursion_limit = 25
CrewAI	max_iter = 25
pydantic-ai	request_limit = 50
OpenHands	max_iteration_per_run = 500
Google ADK LoopAgent	max_iterations = None → sınırsız

Doküman ≠ kod — Hermes, aynı dosyada

init_agent(max_iterations=...) gerçek varsayılan **sys.maxsize** (:523)
aynı fonksiyonun docstring'i: **"default: 90"** (:603)

Asıl bulgu

24 harness'ın 12'sinde mekanizma var — varsayılanda KAPALI

Gemini CLI maxSessionTurns ?? -1, kontrol > 0 ile korunuyor
config.ts:1243

Continue depth > 50 + NODE_ENV=="test" → üretimde hiç tetiklenmiyor

OpenClaw tools.loopDetection.enabled = false

openclaude **sıfır** döngü tespiti; maxTurns optional, varsayılsız

"Var mı" yanlış soru → "Varsayılanda açık mı?"

İkinci kör nokta: çoğu dedektör yalnız **ardışık** aynı çağrıyı sayıyor.

A→A yakalanıyor · A→B→A→B hiçbir çağrı ardışık tekrarlamıyor.

İlk 22'lik taramada bunu yakalayan: **2 tane** (Gemini CLI k≤5, OpenHands k=2).

#	ZİHNİYET	KAYNAK	AYIRT EDİCİ MEKANİZMA	EN ZAYIF YANI
SEVİYE 1 · SAYAÇ Bir tamsayı. Durum yok, karşılaştırma yok. Yazması bir öğleden sonra · $O(1)$				
1	Modele sorma, say arize-control	Arize — Agent Control Loop	5 durma koşulu + hiyerarşi; adım limiti birincil (modelin hiçbir sözüne bağlı değil). Her koşuma durma sebebi etiketi : <code>completed / max_steps / budget / timeout / error</code>	Ne olduğunu söylemez, sadece "çok oldu"
2	Seçeneksiz bırak agentscope-grace	AgentScope	Limit dolunca 5 turluk lütf + tool_choice kilidi — ajan yeni araç çağıramaz, yalnız cevap üretir	Lütf turları da para yakar
3	Uyarma bile hermes-no-pressure	Hermes agent_init.py:986	Adım ekseninde hiç ara uyarı yok . Tükenmede tek mesaj + bir lütf çağırısı + metin gelmezse zorla özet	Ajan sona kadar bütçesini bilmez
4	Modele saatini göster claude-advisory	Claude Task Budgets	Prompt'a geri sayım; tavsiye, zorlama değil — model aşabilir. Amaç durdurmak değil öngörülebilir iniş	Bütçe yetersizse model işi hiç denemiyor
SEVİYE 2 · PENCERE Son N adımı tut, karşılaştır. Bedeli: "aynı şey" ne demek?				
5	Çeşitliliği ölç strands-entropy	Strands	Tekrarı tanımlamaktan kaç: <code>len(set(pencere)) < eşik</code> . Tek kural, bütün desenler — A-B-A-B dahil, k taraması gerekmiyor	Meşru dar alan çalışması da düşük çeşitlilik
6	Aynı çağırısı say openhands-stuck	OpenHands stuck_detector.py	5 desen, eşikler 4/3/3/6 , pencere 20. Kimlik alanlarını bilerek atar. STUCK ayrı terminal durum — ne başarı ne hata	İmza normalizasyonu yanlışsa sessizce hiçbir şey bulmaz
7	Çözüm de sorun olabilir openclaw-pingpong	OpenClaw 2026.7.1 K	<code>genericRepeat / knownPollNoProgress / pingPong</code> ; kademe 10→20→30 ; parmak izi = araç+arg+ sonuç ; compaction sonrası 3 deneme koruması	Varsayılarda kapalı; 160 run-retry sınırı çok gevşek
8	Hareket #ilerleme loopguard-dignity	Ne Zaman Durması Gerektiğini Bilen Ajanlar	Eyleme değil sonuca bak: son 3 <code>state_hash</code> aynıysa dur. Araç başına <code>retry</code> . Çekimsiz kalma = meşru sonuç (<code>NEEDS_INPUT</code>). 4 alanlı durma raporu	Hızlı+ucuz döngüler sınırlar dolmadan çok döner
SEVİYE 3 · DÜNYA Davranışı bırak, kanıta geç. En tehlikeli hata döngü değil — yanlış işi doğru sanmak				
9	"Bitirdim" bir istektir verify-gate	Loop Engineering	Bitirme iddiası bir kapiya bağlı. Kapı açılmazsa koşum bitmez — doğrulama sonucu gözleme geri döner, ajan kendi hatasını düzeltir	Ajan hiç "bitirdim" demezse kapı hiç açılmaz
10	Suç araçta olabilir galileo-breaker	Galileo AI	Sayı değil oran : aracın son çağrılarının yüzde kaçını hata verdi. Devre kesici araç başına	Kalıcı bozuk araçla geçici hatayı ayırt etmesi eşiğe bağlı
11	Doları say agentbudget-dollar	AgentBudget	Nihai cevap payı (sert limit erken tetiklenir, ajan toparlayabilir) · iç içe alt bütçe · zaman pencereli tespit ("dakikada 10 çağrı") · <code>terminated_by</code>	Fiyat tablosu bakım gerektirir
SEVİYE 4 · ŞEKİL Tespiti bırak, mimariyi değiştir. Mevcut ajana sonradan eklenemez				
12	Serbestliği kısıtla modexa-statemachine	Modexa	ANLA→TOPLA→EYLEM→DOĞRULA→YANIT→DEVRET, yalnız izinli geçiş. DOĞRULA→TOPLA yok . 5 basamaklı geri dönüş merdiveni; "kullanıcıya sor" birinci sınıf sonuç	Öngörülemez işler makineye sığmaz
13	Koşmadan yakala autogen-static	AutoGen GraphFlow	Graf doğrulamasında <code>Cycle detected without exit condition</code> → sistem hiç başlamaz . Çalışma zamanında 0 maliyet, 0 yanlış pozitif	Yalnız yapısal döngü; model içi takılmayı görmez
SEVİYE 5 · KADEME Çok sinyal + basamaklı müdahale + geri alma. Durum makinesi artık dedektörün içinde				
14	Kural koy, ihlali söyle, geri sar telemetry-repair	Real-Time Detection and Repair T	3 deterministik kontrol + checkpoint'e geri sarma. Onarım mesajı " hangi kontrol düştü "	Checkpoint tutmak mimariye ciddi yük; döngüde onarım işe yaramıyor
15	Altı ucuz sinyal pi-signature	pi-anti-doom-loop	≥%55 kelime örtüşmesi ile yakın-benzer metin — gömme modeli yok, sadece kelime sayma. Metin: yönlendir→kes · Araç: engelle→sebep→turu bitir	Altı sinyal × ayrı eşik × iki merdiven — yanlış uygulanırsa sessizce ölür
SEVİYE 6 · KARAR "Ne zaman dur" yanlış soru				
16	Tavan değil, tahsis voi-allocation	Inference-Time Budget Control T	Birim bütçe başına fayda . Çift bütçe (araç + token). Baskı en kritik eksene göre: $p = 1 - \min(\dots)$. Erken cevabı engelleyen guard'lar	Döngünün içine girer — yanlış ayarlanırsa ajanı bozar. Bol bütçede kazanç erir
17	Eşiği ölç improvement-loop	OpenAI cookbook + 2 kaynak	Müdahale yok, sadece iz. Tavanı başarılı koşum dağılımından (p99). Eşikler prompt'la birlikte sürümlensin , terfi kapisından geçsin	Bu koşumu kurtarmaz; veri birikmesini bekler

Hiçbirinin çözemediği bir döngü sebebi — Modexa

Ajanın "**yanlış yapmamak**" üzerine optimize edilmesi. Aşırı tedbir teşvik eden bir prompt, en güvenli yolu "bir kez daha doğru" yapıyor. Ajan bozuk değil — **tam da söylendiği gibi davranıyor**. "*Bir sorun çözücü inşa etmediniz. Bir riskten kaçınma makinesi inşa ettiniz.*" → Kaynağı kod değil **prompt**; 17 mekanizmanın hiçbirisi çözümüyor, hepsi ancak sonucu kesiyor.

04 SUNUMDA SÖYLENECEK SAYILAR

SAYI	NE DİYOR	KAYNAK
%96 / 0 yanlış pozitif	3 deterministik kural (toplam tutarlılığı · gerekli araç kapsaması · araç sözleşmesi) hataların %96'sını yakalıyor, 0/63 yanlış alarm . Eğitilmiş istatistiksel monitör: %54 / 11-63 = %17. Basit olan, karmaşık olanı hem yakalamada hem yanlış alarmda yeniyor.	Real-Time Detection and Repair T
%45 vs %36	Onarımda ajana " hangi kontrol düştü " demek (%45), doğru cevabı vermekten (%36) iyi. Hiçbir şey demeden yeniden dene: %16. → Cevabı verince ajan kopyalar, neden yanlışlığını anlamaz.	aynı kaynak T
F1 0,63 → 0,43	Bütçe-bağımlı ceza bileşeni çıkarılınca performans her veri setinde düşüyor. Ana sonuç "puanlama kullandık" değil — kalan bütçeyi eylem seçimine açıkça katmak .	Inference-Time Budget Control T
20,91 → 15,23 sn (−%27,2)	Kontrolcü ek hesap katmanını olmasına rağmen süreyi düşürüyor — önlenen aramaların ağ gecikmesi, puanlama maliyetinden onlarca kat büyük. " Kontrol yavaşlatır " itirazının cevabı.	aynı kaynak T
\$2,45 vs \$134,50 ≈55× 36 koşumun 21'i	Warming (GPT-4) %93,2 doğruluk / \$2,45 · LATS (GPT-4) %88,0 / \$134,50 — pahalı arama, eşit ya da daha kötü doğruluk . Ve daha yüksek "reasoning effort" 36 koşumun 21'inde doğruluğu artırmıyor . Bütçeyi büyütme çözüm değil .	AI Agents That Matter T Holistic Agent Leaderboard T

05 ÜÇ KARŞITLIK — SUNUMUN EN ÖĞRETİCİ KISMI

Uyar mı, uyarma mı? Claude: modele geri sayımı göster, kendini ayarlasın. Hermes agent_init.py:986 — denedi, kaldırdı: "Ara basınç uyarıları yok — modelleri karmaşık görevlerde erken pes ettiriyordu." Ama aynı sistem süre ekseninde %80'de uyarıyor. → Eksene göre karar ver. Adımda uyarma, sürede uyar.	Tavan mı, tahsis mi? 16 strateji: "ne zaman dur?" — tavana kadar ajan ne yaparsa yapsın. voi-allocation: "parayı nereye harca?" — aynı bütçeyle daha iyi sonuç. → İkisi de gerekli. Tahsis tavana kadarki yolu verimli kullanır; tavan, tahsis yanılırsa keser.	Guardrail mı, mimari mi? 17 zihniyet: model döngüde, biz sınırlıyoruz. OpenAdapt reddediyor: görevi bir kez göster, deterministik programa derle. "Sağlıklı koşumlar hiçbir üretken model çağırısı yapmaz." → Döngüde model yoksa döngü de yok. Bedeli: yalnız tekrarlanan işler.
--	---	---

06 POC — CUA_LAB · 8/17 ZİHNİYET KODDA, SEÇİLEBİLİR **M**

Bağımlılık yok · API anahtarı yok · **46 test**. --strategy a,b ile üst üste konabiliyor. Hata **modelde değil ortamda**: 5 senaryo × 5 model.

senaryo	dead_button	model	stubborn			
strateji	durum	sebept	adim	token	\$	
none	CEILING	hard_ceiling	300	105000	1.050	
openhands-stuck	STUCK	cycle_k2	3	1050	0.011	
strands-entropy	STUCK	low_diversity	6	2100	0.021	
loopguard-dignity	NEEDS_INPUT	abstain_need_input	7	2450	0.025	
agentbudget-dollar	BUDGET_EXHAUSTED	budget_steps	12	3850	0.038	
arize-control	BUDGET_EXHAUSTED	max_steps	13	4200	0.042	
galileo-breaker	CEILING	hard_ceiling	300	105000	1.050	<- kor nokta
verify-gate	CEILING	hard_ceiling	300	105000	1.050	<- kor nokta

Sekiz zihniyet, sekiz farklı sonuç. Son iki satır kasıtlı: galileo-breaker hata oranına bakar, bu senaryoda hata yok; verify-gate bitirme iddiası bekler, ajan hiç "bitirdim" demez. **Kör noktalar tabloda görünüyor** — "tek katman yetmez"in kanıtı.

her zihniyetin kendi yakaladığı senaryo				
broken_tool + patient	galileo-breaker	DEGRADED	tool_circuit_open	
healthy + liar	verify-gate	DEGRADED	verify_failed	
dead_button + alternating	strands-entropy	STUCK	low_diversity	(A-B-A-B)
KONTROL — healthy / flaky / silent_success: 8 sütunun 8'i de none ile BİREBİR AYNİ (aynı adim, aynı token). 46 test kilitliyor.				

PoC'nin öğrettiği üç şey

- 1 · İki mekanizma birbirini maskeliyor.** max_replans=3 retry döngüsünü dedektörden **önce** yakaladı. Koşum doğru durdu, **teşhis kayboldu**. → Bütçe *bir şeyin*, döngü tespiti *neyin* yanlış gittiğini söyler.
- 2 · Gevşek sinyal sıkıyı gizliyor.** "İlerleme yok" dönüşümlü döngüyü "ilerleme yok" diye raporladı — doğru ama işe yaramaz teşhis. → En gevşek sinyalin eşiği **en yüksek** olmalı, **en son** tetiklenmeli.
- 3 · Kaynağın sayıları taşınmıyor.** loopguard'ın no_progress=3 · retries=2 eşikleri flaky içinde meşru koşumu **başarıdan bir adım önce** kesiyor (ölçülmüş değerimiz 8). Ayrıca dict[araç,int] metin ajanı varsayıyor — computer use'da left_click için %90'ı. → **Zihniyet doğru, sayılar başka alandan**.

10 CANLI DEMO — KOPYALA-YAPIŞTIR

```
cd reliability_study/cua_lab # komutların onune: python3 -m
# model: stubborn = sikisan (varsayılan) | patient = cozen

# kontrolsuz -> 300 adim, tavana carpiyor
cua_lab.cli run --strategy none --scenario dead_button
# dedektor acik -> 3 adimda duruyor
cua_lab.cli run --strategy openhands-stuck --scenario dead_button
# yan yana tablo (sunumun ana ciklisi)
cua_lab.cli compare --scenario dead_button --strategies all
# verify-gate: yapmadan "bitirdim" diyeni yakalar
cua_lab.cli compare --scenario healthy --model liar --strategies none,verify-gate
# ust uste koyma
cua_lab.cli run --strategy verify-gate,arize-control --model liar
# KONTROL: butun sutunlar birebir ayni olmalı
cua_lab.cli compare --scenario flaky --strategies all --model patient
cua_lab.cli replay <trace.json> # izi adim adim oynat
```

Demo sırasında söylenecekler

- 1'de:** "Anthropic'in referans döngüsü. 300'de duruyor çünkü demo güvenliği için tavan koydum — **gerçek üretimde o tavan da yok**."
- 2'de:** "Aynı model, aynı bozuk ortam. Tek fark bir dedektör. **3 adım, 1 sent**."
- 4'te — asıl gösterilecek:** "Meşru retry. İki sütun **birebir aynı** — guardrail çalışan koşuma tek token bindirmiyor. **Dedektörün ikinci sınavı budur**."

Senaryolar: dead_button · broken_tool · flaky · silent_success · healthy **Modeller:** stubborn · alternating (A-B-A-B) · liar · patient · solver

07 ENTEGRASYON GEREKLİLİKLERİ

Zorunlu — bunlar olmadan hiçbirisi çalışmaz

- İterasyon başına span.** Bütün koşturucu tek span'a 4–19. adımların aynı çağrı olduğunu göremezsin. Loop detection her şeyden önce bir **gözlemlenebilirlik** gereksinimi.
- İmza normalizasyonu.** Hangi alanlar her turda değişiyor, hangileri anlam taşıyor — envanteri çıkarılmalı. Sisteme özel; kütüphane halletmiyor. **Yanlış yaparsan sessizce çalışmayan dedektör.**
- Terminal durum ayrımı.** `completed / max_steps / budget / timeout / error / stuck` ayrı ayrı — tek başarı oranına karışmadan.
- Çok eksenli sayaç.** Adım · replan · token · süre · dolar. Tek eksen diğerlerini gizler.
- Nihai cevap payı.** Sert limit biraz erken tetiklensin ki ajan elindekini toparlasın.

Tavsiye edilen

- Kapatma anahtarı olsun ama **varsayılan AÇIK** — 12/24 harness'in yaptığı hata.
- Eşikler prompt'la **birlikte sürümlensin**, terfi kapısından geçsin.
- Yanlış pozitif için **ayrı kontrol koşumları** — CI'da, "tetiklenmemeli" testleri.

08 BEKLENEN SORULAR — HAZIR CEVAPLAR

"Hepsini uygulamak gerekiyor mu?" Hayır. Seviye 1 tek başına vakaların çoğunu durduruyor — ama *neden* durduğunu söylemiyor. Kaç katman, teşhis ihtiyacına bağlı.

"Gerçek modelle test ettin mi?" Hayır — bilinçli. Kontrol mekanizmasını göstermek için girdi **deterministik** olmalı. Gerçek LLM'le aynı döngüler çıkar ama her koşturumda farklı, üstelik para yakar. HF Inference bağlantısı son fazda.

"Eşikleri nereden aldın?" Kaynaklardan (OpenHands 4/3/3/6, OpenClaw 10/20/30). **Tahmin olduğunu kabul ediyorum** — 17 numara tam olarak bunun eleştirisi. Doğrusu kendi dağılımından çıkarmak.

Nereden başlanmalı

1 → 6 → 2

- 1 · Sayaç** — bir öğleden sonra. Sert durdurma + durma sebebi kaydı.
- 6 · Ölç** — izleri topla, eşikleri dağılımdan çıkar (p99).
- 2 · Pencere** — dedektörleri **ölçülmüş eşiklerle** yaz.

Eşiği ölçmeden pencere yazmak, hangi sayıyı yazacağını bilmeden yazmak demek.

Dezavantajlar — dürüst liste

- Yanlış pozitif gerçek maliyet.** Meşru toplu işlem döngü sayılabilir.
- Sessizce ölebiliyorlar** — ve **testleri geçerler**, çünkü testler "yakaladı mı" diye bakar.
- Eşikler tahmin.** Dar limit grafikte "model kötüleşti" gibi görünür.
- Birbirlerini maskeliyorlar.** Sıralama ve eşik dengesi tasarım işi.
- Kapsam sınırlı.** Doğrulama kapısı ajan bitirmezse sessiz; statik analiz model içi takılmayı görmez; tahsis bol bütçede erir.
- Uyarı geri tepebilir** — adım ekseninde ölçülmüş.
- Prompt kaynaklı döngüyü hiçbirisi çözüyor.**

"Yanlış pozitif riski?" Ölçtüğüm kadarıyla kontrol senaryolarında sıfır — ama iki senaryo gerçek çeşitlilik değil. Literatürden: deterministik kontroller **0/63**, istatistiksel **%17**. Deterministik tercih etme gerekçem bu.

"Ne kadar iş?" Seviye 1 bir öğleden sonra. En büyük kalem **gözlemlenebilirlik** (iterasyon başına span) — mevcut loglama şemasına dokunuyor. Dedektörlerin kendisi birkaç yüz satır.

"IAL-SCAN / statik analiz neden yok?" O çalışma dağıtımdan **önce** kodu okuyor — CI'a giren bir şey. Bizim ihtiyacımız çalışma anı. Ondan alınan tek şey **soru biçimi**: "döngü var mı" değil, "*ajanik bir geri besleme yolu, maliyetli bir işlemi etkili bir sınır olmadan tekrar tekrar çalıştırabilir mi?*"

09 KAYNAK KÜNYESİ — HER SAYININ NEREDEN GELDİĞİ

SAYI / İDDİA	KAYNAK	ETİKET
%15,7 · %12,4 (adım tekrarı, durma koşulu)	<i>Why Do Multi-Agent LLM Systems Fail?</i> — 1642 iz, 7 framework	T tam metin
63 olay · "ödemeden önce engellenmiş tek vaka yok"	<i>Token Budgets: An Empirical Catalog</i> — 21 framework, κ=0,837	T kısmi
<code>while True</code> , sayaç yok	<code>anthropics/claude-quickstarts</code> → <code>computer_use_demo/loop.py</code>	K kod
<code>maxSessionTurns ?? -1</code>	Gemini CLI <code>packages/core/src/config/config.ts:1243</code>	K kendim
<code>depth > 50 + NODE_ENV=="test"</code>	<code>Continue gui/src/redux/thunks/streamNormalInput.ts:80</code>	K kendim
<code>loopDetection.enabled = false</code> · 10/20/30	openclaw 2026.7.1-2 — bu makinedeki kurulum	K yerel
<code>max_iterations = None</code> (sınırsız)	Google ADK <code>LoopAgent</code>	K kod
4/3/3/6, pencere 20, STUCK terminal	OpenHands <code>software-agent-sdk</code> → <code>stuck_detector.py</code>	K kod
"erken pes ettiriyordu" · <code>sys.maxsize</code> vs docstring "90"	Hermes <code>agent_init.py:986–991</code> · :523 / :603	K birebir
%16 / %36 / %36 / %45 · %96-0FP vs %54-%17	<i>Real-Time Detection and Repair of LLM Agent Failures</i>	T tam metin
F1 0,63→0,43 · 20,91→15,23 sn	<i>Inference-Time Budget Control for LLM Search Agents</i>	T tam metin
\$2,45 vs \$134,50 (≈55×) · 36 koşturumun 21'i	<i>AI Agents That Matter · Holistic Agent Leaderboard</i>	T tam metin
300/105000/\$1,050 vs 3/1050/\$0,011 · kontrol birebir	<code>cua_lab</code> — kendi koşturumum, tekrarlanabilir	M ölçüldü

Kapanış — tek cümle

Model döngüyü kesemez; **kesme kararı için gereken bilgi onun görüş alanında değil**. Kesme yetkisi dışarıda olmalı — ve dışarı **ne olduğunu da söyleyebilmeli**.

"Her ajan döngüsünün **tasarlanmış bir çıkışı** olmalıdır — başarı, geri dönüş, sorma veya devretme. 'Sonsuza kadar dene' değil. 'Umarım model çözer' değil." — Modexa